

Análisis de teoría de colas aplicado a la operación de la Heladería Crepes & Waffles: Un Estudio Comparativo entre Franjas Horarias

*Queueing Theory Analysis Applied to the Operation of Crepes & Waffles Ice Cream Parlor: A
Comparative Study Between Time Slots*

Katheryn Guasca¹, Laura Garzón²
Fabio Triana³, Damian Rey⁴

RESUMEN

Este estudio aplica la teoría de colas al análisis del sistema de atención de la Heladería Crepes & Waffles ubicada en la Carrera 7 de Bogotá, con el objetivo de comparar el desempeño operativo del sistema en dos franjas horarias con niveles de demanda diferenciados. A partir de una observación directa de una hora por franja, se registraron las horas de llegada de los clientes, los tiempos de inicio de atención, los tiempos de finalización del servicio y el número de servidores activos.

Para el cálculo de los parámetros del modelo se diferenciaron dos tipos de registros. La tasa de llegada λ se estimó con todos los clientes que ingresaron al sistema durante la hora observada, mientras que la tasa de servicio μ se calculó únicamente con los clientes que tuvieron registros completos de inicio y finalización del servicio. Esta separación fue necesaria porque, durante la franja de la tarde, varios clientes llegaron al sistema, pero no alcanzaron a completar su atención dentro del periodo de observación.

Los resultados evidencian que la franja de la mañana opera bajo condiciones estables, con una utilización de $\rho = 0.47$. En contraste, la franja de la tarde presenta una utilización de $\rho = 2.88$ bajo el modelo M/M/1, lo que indica saturación del sistema y pérdida de validez de las métricas estacionarias tradicionales como L_q , W_q , L y W . De acuerdo con la teoría de colas, un sistema M/M/1 solo alcanza estabilidad cuando la tasa de llegada es menor que la tasa de servicio, es decir, cuando $\rho < 1$ [2].

¹ Grupo de Investigación XXXX, Universidad XXX (Ciudad, País) Dirección: XXXXX, PBX: XXXX. ORCID ID: <https://orcid.org/> Correo electrónico institucional: XXX.

² Grupo de Investigación XXXX, Universidad XXX (Ciudad, País). Dirección: XXXXX, PBX: XXXX . ORCID ID: <https://orcid.org/> Correo electrónico institucional: XXX.

³ Grupo de Investigación XXXX, Universidad XXX (Ciudad, País) Dirección: XXXXX, PBX: XXXX. ORCID ID: <https://orcid.org/> Correo electrónico institucional: XXX.

⁴ Grupo de Investigación XXXX, Universidad XXX (Ciudad, País). Dirección: XXXXX, PBX: XXXX . ORCID ID: <https://orcid.org/> Correo electrónico institucional: XXX.

Por esta razón, el análisis se complementó con una simulación desarrollada en Python, la cual permitió visualizar la acumulación progresiva de clientes y comparar distintos escenarios de mejora [6],[7]. Los resultados muestran que M/M/2 continúa siendo insuficiente, M/M/3 estabiliza el sistema de manera crítica y M/M/4 representa la alternativa más conveniente para reducir la congestión y mejorar la experiencia del cliente.

Palabras clave: teoría de colas, M/M/1, M/M/c, simulación, tiempo de espera, sistemas de servicio.

1. INTRODUCCIÓN

La gestión eficiente del flujo de clientes en sistemas de atención es un factor determinante para la calidad del servicio y la experiencia del usuario. En establecimientos de atención directa al público, los tiempos de espera influyen en la percepción del servicio, la satisfacción del cliente y la capacidad operativa del sistema. Cuando la demanda supera la capacidad disponible, se generan filas, acumulación de clientes y pérdida de eficiencia.

En este contexto, la teoría de colas permite analizar matemáticamente sistemas donde los clientes llegan de manera aleatoria y deben esperar cuando los servidores se encuentran ocupados [2],[3],[4]. Este enfoque permite relacionar la tasa de llegada, la tasa de servicio y la utilización del sistema con indicadores como el tiempo promedio de espera, la longitud de la cola y el número promedio de clientes en el sistema [2],[3],[5]. Asimismo, los modelos con uno o varios servidores permiten comparar el desempeño del sistema bajo diferentes configuraciones de capacidad [1],[4],[9].

El presente estudio analiza la operación de la Heladería Crepes & Waffles ubicada en la Carrera 7 de Bogotá. El caso fue seleccionado porque presenta diferencias visibles entre una franja de baja demanda y una franja de alta congestión. Para ello, se realizó una observación directa durante una hora en cada franja, registrando las horas de llegada, inicio de atención y finalización del servicio.

El análisis se apoya inicialmente en el modelo M/M/1, debido a que el sistema fue observado con un servidor principal de atención. Posteriormente, se evaluaron escenarios M/M/c con dos, tres y cuatro servidores, con el fin de analizar el impacto de aumentar la capacidad durante la franja de mayor demanda. Estos modelos son útiles para evaluar indicadores como utilización, longitud promedio de cola y tiempo de espera en sistemas con varios puntos de atención [1].

Además del análisis teórico, se desarrolló una simulación en Python para representar el comportamiento dinámico del sistema. Esta simulación permitió observar la evolución de la cola durante la hora de análisis y comparar diferentes escenarios de mejora.

2. REVISIÓN DE LITERATURA

La teoría de colas es una herramienta matemática utilizada para analizar sistemas donde existe una demanda aleatoria frente a una capacidad limitada de servicio [2],[3],[5]. Su aplicación permite estudiar el comportamiento de las llegadas, los tiempos de atención, la utilización de los recursos y la formación de filas. Según Saini, Singh y Sharma, los modelos de colas permiten evaluar indicadores de desempeño como la utilización del sistema, el tiempo promedio de espera, el tiempo promedio en el sistema y la longitud promedio de cola [2],[3],[5].

Dentro de los modelos más utilizados se encuentra el modelo M/M/1, el cual representa un sistema con un solo servidor, llegadas

aleatorias y tiempos de servicio exponenciales [3],[5],[8]. En este modelo, la estabilidad depende de que la tasa de llegada sea menor que la tasa de servicio, es decir, que la utilización ρ sea menor que 1. Cuando ρ se aproxima a 1, el sistema opera cerca de su límite de capacidad; cuando $\rho \geq 1$, el sistema no alcanza estado estacionario y las métricas tradicionales como L_q y W_q dejan de ser aplicables [2],[3],[5].

Para sistemas con varios puntos de atención se utilizan modelos M/M/c, donde c representa el número de servidores disponibles [1],[4],[9]. Chaudhary et al. señalan que estos modelos permiten analizar el efecto de la capacidad de servicio sobre indicadores como la longitud de cola, los tiempos de respuesta y la utilización del sistema [1]. Por esta razón, el modelo M/M/c resulta adecuado para evaluar escenarios de mejora en la heladería, especialmente durante la franja de la tarde, donde la demanda observada supera la capacidad de un solo servidor.

3. METODOLOGÍA

3.1 DESCRIPCIÓN DEL SISTEMA

El sistema analizado corresponde a la atención de clientes en la Heladería Crepes & Waffles de la Carrera 7. Los clientes llegan al establecimiento, ingresan a una fila si el servidor está ocupado y posteriormente son atendidos por el personal disponible. Durante la observación se identificó que el sistema operaba inicialmente con un servidor principal de atención.

3.2 RECOLECCIÓN DE DATOS

La recolección de datos se realizó mediante observación directa durante una hora por franja. En cada sesión se registraron las siguientes variables:

- Hora de llegada: Momento en que el cliente ingresó al sistema

- Inicio de atención: Momento en que el cliente comenzó a ser atendido
- Fin de atención: Momento en que terminó el servicio
- Número de servidores: Cantidad de puntos de atención activos



Figura 1. Observación en la franja de la mañana Jueves 23 abril 2026(10:47 a.m.)



Figura 2. Observación en la franja de la tarde Martes 21 de abril 2026(1:34 p.m.)

En la franja de la mañana se observaron 11 llegadas, de las cuales 10 tuvieron servicio completo registrado. En la franja de la tarde se observaron 46 llegadas, de las cuales 15 tuvieron registros completos de inicio y fin de atención.

Esta diferencia es importante porque no todos los clientes que llegan alcanzan a completar su atención dentro de la hora observada. Por esta razón, se decidió utilizar todos los clientes que

llegaron para calcular la tasa de llegada λ , y únicamente los servicios completos para calcular la tasa de servicio μ . Esta decisión es coherente con la lógica de la teoría de colas, donde λ representa la demanda que entra al sistema y μ representa la capacidad efectiva de atención del servidor [2],[3].

3.3 TRATAMIENTO DE REGISTROS INCOMPLETOS

Uno de los ajustes principales del análisis fue separar los datos en dos grupos:

- Todos los clientes que llegaron → Cálculo de λ
- Clientes con inicio y fin de atención → Cálculo de μ

Esta decisión evita subestimar la demanda real del sistema. Si en la tarde solo se utilizaran los 15 clientes con servicio completo para calcular λ , se ignoraría a los demás clientes que sí llegaron y se acumularon en la fila. Por lo tanto, la lógica utilizada fue:

$$\lambda = \frac{\text{clientes que llegaron}}{60}$$

$$\mu = \frac{1}{\text{tiempo promedio de servicio}}$$

$$\rho = \frac{\lambda}{\mu}$$

Para los escenarios con múltiples servidores, se empleó:

$$\rho = \frac{\lambda}{c\mu}$$

donde c corresponde al número de servidores [3],[5]. Esta expresión permite analizar el efecto de distribuir la demanda entre varios puntos de atención [1],[4],[9].

4. RESULTADOS

4.1 RESUMEN DE DATOS RECOLECTADOS

A continuación, se presentan los datos observados para cada franja horaria. Los promedios y parámetros del modelo se calculan exclusivamente con los registros incluidos en estas tablas, garantizando consistencia entre la información recolectada y los resultados del modelo.

Tabla 1. Datos observados en la franja de la mañana

Cliente	Hora llegada	Inicio atención	Fin atención
1	10:51:12	10:51:12	10:53:44
2	10:55:39	10:55:39	10:57:59
3	11:02:04	11:02:04	11:04:23
4	11:06:18	11:06:18	11:09:17
5	11:10:16	11:10:16	11:12:20
6	11:16:13	11:16:13	11:19:12
7	11:20:35	11:20:35	11:23:26
8	11:25:42	11:25:42	11:28:32
9	11:32:00	11:32:00	11:34:16
10	11:37:44	11:37:44	11:40:25
11	11:43:43	11:43:43	No registrado

Tabla 2. Datos observados en la franja de la tarde

Cliente	Hora llegada	Inicio atención	Fin atención
1	12:46:46	12:46:46	12:52:12
2	12:48:10	12:52:12	12:55:17
3	12:49:00	12:55:17	12:57:40
4	12:49:56	12:57:40	13:03:08
5	12:51:18	13:03:08	13:05:23
6	12:52:54	13:05:23	13:09:07
7	12:54:04	13:09:07	13:13:59
8	12:55:10	13:13:59	13:16:46
9	12:56:15	13:16:46	13:19:19
10	12:58:00	13:19:19	13:23:38
11	12:59:16	13:23:38	13:26:53

12	13:00:42	13:26:53	13:30:29
13	13:01:35	13:30:29	13:34:18
14	13:02:38	13:34:18	13:39:48
15	13:03:45	13:39:48	13:43:03
16	13:04:44	13:43:03	No registrado
17	13:06:25	No registrado	No registrado
18	13:07:32	No registrado	No registrado
19	13:08:34	No registrado	No registrado
20	13:09:58	No registrado	No registrado
21	13:11:43	No registrado	No registrado
22	13:12:36	No registrado	No registrado
23	13:14:12	No registrado	No registrado
24	13:15:46	No registrado	No registrado
25	13:16:55	No registrado	No registrado
26	13:18:30	No registrado	No registrado
27	13:19:42	No registrado	No registrado
28	13:21:18	No registrado	No registrado
29	13:22:58	No registrado	No registrado
30	13:23:59	No registrado	No registrado
31	13:25:37	No registrado	No registrado
32	13:27:05	No registrado	No registrado
33	13:28:41	No registrado	No registrado
34	13:29:59	No registrado	No registrado
35	13:31:14	No registrado	No registrado
36	13:32:58	No registrado	No registrado
37	13:34:08	No registrado	No registrado
38	13:35:31	No registrado	No registrado
39	13:36:40	No registrado	No registrado
40	13:37:30	No registrado	No registrado
41	13:38:33	No registrado	No registrado
42	13:39:33	No registrado	No registrado
43	13:41:16	No registrado	No registrado
44	13:42:33	No registrado	No registrado
45	13:43:41	No registrado	No registrado
46	13:44:44	No registrado	No registrado

Adicionalmente, se registraron variables más detalladas como la hora exacta de llegada a la

fila, inicio de atención y finalización del servicio, permitiendo una representación más precisa del comportamiento del sistema en cada franja.

4.2 DATOS PROCESADOS

A partir de los datos recolectados, se calcularon los valores promedio del tiempo entre llegadas y del tiempo de servicio para cada franja horaria. Estos valores permiten simplificar el análisis y constituyen la base para el modelado del sistema de colas.

Tabla 3. Datos promedio por franja horaria

Franja horaria	Número de Clientes	Servicios completos usados para μ	Tiempo promedio entre llegadas	Tiempo promedio de servicio	Servidores
Mañana	11	10	5.25	2.58	1
Tarde	46	15	1.29	3.75	1

Como se observa en la Tabla 3, la franja de la tarde tiene una demanda mucho mayor. En la mañana llega un cliente aproximadamente cada 5.25 minutos, mientras que en la tarde llega un cliente aproximadamente cada 1.29 minutos. Además, el tiempo promedio de servicio también aumenta en la tarde, pasando de 2.58 a 3.75 minutos.

Esto genera una doble presión operativa: llegan más clientes y cada cliente tarda más tiempo en ser atendido. De acuerdo con la teoría de colas, cuando la tasa de llegada aumenta y la tasa de servicio disminuye, la utilización del sistema se incrementa y el riesgo de congestión crece [2],[3],[5].

4.3 Parámetros del Modelo

Tabla 4. Parámetros del modelo de colas

Franja horaria	λ (clientes/min)	μ (clientes/min)	ρ (utilización)
Mañana	0.18	0.39	0.47
Tarde	0.77	0.27	2.88

En la franja de la mañana, la tasa de llegada es menor que la tasa de servicio, por lo que el sistema opera de forma estable. En cambio, en

la franja de la tarde, la tasa de llegada supera ampliamente la capacidad de atención de un solo servidor. Esto se refleja en una utilización de $\rho = 2.88$, lo que significa que el modelo M/M/1 no puede alcanzar estado estacionario.

Este resultado es consistente con los fundamentos del modelo M/M/1, en el cual la estabilidad se alcanza únicamente cuando $\rho < 1$ [2],[3].

4.4 MÉTRICAS DE DESEMPEÑO DEL SISTEMA

A partir de los parámetros del modelo, se calcularon las principales métricas de desempeño del sistema, tales como la longitud promedio de la cola (Lq), el tiempo promedio de espera en la cola (Wq) y el tiempo total en el sistema (W).

Tabla 5. Métricas de desempeño del sistema

Métrica	Franja 1 (Mañana)	Franja 2 (Tarde)
ρ (utilización)	0.47	2.88
Lq (clientes en cola)	0.43	No aplica
Wq (espera en cola, min)	2.33	No aplica
L (clientes en sistema)	0.90	No aplica
W (tiempo en sistema, min)	4.91	No aplica
Estado del sistema	Estable	Saturado

La franja de la mañana presenta un comportamiento adecuado. La utilización del servidor es inferior a 1, la cola promedio es menor a un cliente y el tiempo promedio de espera se mantiene en un nivel razonable. Esto indica que, durante esta franja, un solo servidor es suficiente para atender la demanda observada.

En la franja de la tarde, las métricas estacionarias del modelo M/M/1 no son aplicables porque $\rho > 1$. Esto significa que el sistema no tiene capacidad suficiente para atender la demanda promedio. En términos prácticos, la cola tiende a crecer durante el periodo de observación.

Cuando la utilización es mayor o igual a 1, el sistema no alcanza estado estable y los indicadores teóricos tradicionales pierden validez [2]. Por esta razón, el análisis de la franja de la tarde se complementó con simulación en Python.

5. EXPLICACIÓN DEL ANÁLISIS REALIZADO EN PYTHON

La simulación en Python se realizó con el objetivo de representar dinámicamente el comportamiento del sistema de atención durante un horizonte de 60 minutos. El código fue corregido para diferenciar entre clientes que llegaron al sistema y clientes con servicio completo [6],[7].

Primero, se organizaron los datos en dos listas principales por franja. La primera lista contiene todas las llegadas observadas, mientras que la segunda contiene únicamente los clientes que tuvieron hora de llegada, inicio de atención y finalización del servicio. Esta separación permitió calcular correctamente λ y μ .

Luego, se calcularon los parámetros principales del modelo:

$$\mu = \frac{1}{\text{tiempo promedio de servicio}}$$

$$\rho_{M/M/1} = \frac{\lambda}{\mu}$$

$$\rho_{M/M/c} = \frac{\lambda}{c\mu}$$

Después se implementaron funciones para evaluar el modelo M/M/1 y el modelo M/M/c. Para M/M/1, si ρ era menor que 1, se calcularon Lq, Wq, L y W. Si ρ era mayor o igual a 1, el código marcó el sistema como saturado y dejó esas métricas como no aplicables, siguiendo la condición de estabilidad de los modelos de colas [2].


Posteriormente, se simuló el comportamiento del sistema usando llegadas aleatorias y tiempos de servicio aleatorios [6],[8]. La simulación permitió observar cuántos clientes estaban en el sistema y cuántos

estaban esperando en cola a lo largo del tiempo. También se evaluaron escenarios de mejora, incluyendo reducción del tiempo de servicio y aumento del número de servidores.

Finalmente, se generaron trece gráficas agrupadas en dos bloques: diagnóstico del sistema actual y comparación de escenarios de mejora. El uso de modelos M/M/c permitió analizar cómo cambia la utilización al aumentar el número de servidores disponibles [1].

6. ANÁLISIS DE GRÁFICAS DEL DIAGNÓSTICO


Gráfica 1. Línea de tiempo observada: llegadas y servicios



La primera gráfica muestra la diferencia operativa entre ambas franjas. En la mañana, los bloques de servicio aparecen separados entre sí, lo que indica que el servidor tiene periodos de inactividad. Esto coincide con una baja tasa de llegada y con un sistema estable.

En la tarde, las llegadas aparecen de forma mucho más frecuente y los bloques de servicio se mantienen prácticamente continuos. Esto evidencia que el servidor permanece ocupado y que la demanda supera la capacidad disponible [2],[3],[5]. La cantidad de puntos de llegada en la franja de la tarde confirma que el sistema enfrenta una presión operativa mucho mayor.


Gráfica 2. Parámetros del modelo M/M/1



La gráfica de parámetros confirma la diferencia entre las franjas. En la mañana, $\lambda = 0.18$ y $\mu = 0.39$, por lo que $\rho = 0.47$. Esto indica que el sistema tiene capacidad suficiente para atender la demanda.

En la tarde, $\lambda = 0.77$ y $\mu = 0.27$, por lo que $\rho = 2.88$. Este valor supera ampliamente el límite de estabilidad $\rho = 1$. Por tanto, el sistema M/M/1 se encuentra saturado y no es adecuado para la demanda observada. Esta interpretación es consistente con la teoría de colas, que establece que la estabilidad depende de que la tasa de servicio sea superior a la tasa de llegada [2].

Gráfica 3. Distribución de tiempos de servicio




La distribución de tiempos de servicio muestra que la atención en la tarde es más variable y larga que en la mañana. En la mañana, los tiempos se concentran principalmente entre 2 y 3 minutos. En la tarde, los tiempos se extienden hasta valores superiores a 5 minutos.

Esto indica que en la hora pico no solo llegan más clientes, sino que además los servicios tienden a tardar más. Esta combinación

intensifica la congestión, ya que aumenta la utilización del servidor y reduce la capacidad efectiva del sistema.


Gráfica 4. Simulación M/M/1 - Mañana estable



La simulación de la mañana muestra un sistema con baja acumulación de clientes. Aunque aparecen algunos picos, estos son temporales y se disipan rápidamente. La cola no crece de manera sostenida y el sistema logra autorregularse.

Esto confirma que la franja de la mañana puede operar adecuadamente con un solo servidor. El comportamiento observado es propio de un sistema estable, donde la capacidad de servicio es superior a la demanda promedio [2].


Gráfica 5. Simulación M/M/1 - Tarde Saturada



La simulación de la tarde muestra un crecimiento progresivo del número de clientes en el sistema. La cola aumenta con el paso del tiempo y supera claramente el nivel de referencia de congestión. Este comportamiento es consistente con el resultado teórico de $\rho =$

2.88, ya que la tasa de llegada supera la tasa de servicio del sistema.

Gráfica 6. Utilización según número de servidores



La gráfica compara la utilización del sistema en la franja de la tarde al aumentar el número de servidores junto con el valor de ρ :

$$M/M/1 \rightarrow 2.88$$

$$M/M/2 \rightarrow 1.44$$


$$M/M/3 \rightarrow 0.96$$

$$M/M/4 \rightarrow 0.72$$

El resultado es clave para la propuesta de mejora. M/M/2 no es suficiente, porque mantiene ρ por encima de 1. M/M/3 logra estabilizar matemáticamente el sistema, pero opera muy cerca del límite de saturación. M/M/4 ofrece una utilización más cómoda y mayor margen ante fluctuaciones de demanda.

El análisis de varios servidores se justifica mediante el modelo M/M/c, el cual permite representar sistemas donde la capacidad se distribuye entre varios puntos de atención [1].

Gráfica 7. Distribución de estados - Mañana M/M/1



La distribución de estados de la mañana confirma que el sistema tiene alta probabilidad de permanecer vacío o con pocos clientes. La probabilidad de tener muchos clientes en el sistema disminuye rápidamente, lo cual es característico de un sistema estable.

Este comportamiento refuerza la conclusión de que la franja de la mañana no requiere aumento de capacidad, ya que el servidor tiene suficiente margen operativo.


7. COMPARATIVO DE ESCENARIOS DE MEJORA

Una vez identificada la saturación de la franja de la tarde, se evaluaron dos tipos de mejora:

- Escenario A Reducir el tiempo promedio de servicio manteniendo un solo servidor
- Escenario B Aumentar el número de servidores disponibles

El objetivo fue determinar si la congestión podía resolverse únicamente acelerando el servicio o si era necesario aumentar la capacidad instalada. Los modelos M/M/c permiten evaluar precisamente este tipo de decisiones, ya que muestran cómo cambia la utilización al modificar el número de servidores [1],[4],[9].


Gráfica 8. Utilización según mejora aplicada



La gráfica muestra que reducir el tiempo de servicio ayuda a disminuir la utilización, pero no es suficiente en la mayoría de los casos. Con reducciones del 10%, 20%, 35%, 50% y 65%, el sistema sigue operando con $\rho \geq 1$ o muy cerca del límite de saturación.

Solo con una reducción cercana al 70% del tiempo de servicio el sistema M/M/1 logra una utilización menor que 1. Sin embargo, una reducción de esa magnitud puede ser difícil de implementar en la práctica, porque implicaría disminuir el tiempo promedio de atención de 3.75 minutos a cerca de 1.13 minutos.

Gráfica 9. Tiempo de espera según reducción de servicio




La gráfica muestra que, aun cuando se logra estabilizar el sistema mediante una reducción fuerte del tiempo de servicio, el tiempo de espera puede seguir siendo relevante. Con una reducción del 70%, el W_q es de aproximadamente 7.09 minutos.

Al comparar con los escenarios de múltiples servidores, se observa que M/M/3 tiene un W_q de 28.10 minutos, porque aunque $\rho < 1$, el sistema queda demasiado cerca del límite de saturación. En cambio, M/M/4 reduce el W_q a 1.53 minutos, lo que representa una mejora mucho más conveniente para la experiencia del cliente.

Esto confirma que no basta con lograr estabilidad matemática; también es necesario evaluar si los tiempos de espera resultantes son aceptables para el tipo de servicio analizado.

Gráfica 10. Línea de tiempo simulada: espera y servicio




La línea de tiempo simulada permite observar cómo se comportan los escenarios a lo largo de la hora analizada. En el escenario base M/M/1, los bloques de servicio y espera se extienden durante mucho tiempo, reflejando acumulación de clientes.

El escenario con reducción del 50% mejora la operación, pero todavía muestra continuidad en la ocupación del servidor. M/M/2 reduce parcialmente la presión, pero sigue sin ser suficiente para estabilizar el sistema. M/M/3

mejora el comportamiento, aunque todavía opera con alta ocupación.


Gráfica 11. Distribución de tiempos de espera simulados



La distribución de tiempos de espera muestra que el escenario base M/M/1 genera esperas altas y dispersas. En contraste, los escenarios con más servidores concentran más observaciones cerca de cero, especialmente M/M/3 y M/M/4.

Sin embargo, el análisis teórico muestra que M/M/3 sigue siendo crítico porque opera con $\rho = 0.96$. Por esta razón, aunque M/M/3 puede estabilizar el sistema, no ofrece el mismo margen operativo que M/M/4.


Gráfica 12. Comparación de W_q teórico por escenario



La comparación de W_q muestra que los escenarios con reducciones pequeñas o moderadas del tiempo de servicio siguen siendo inestables. La reducción del 70% logra estabilidad con un W_q de 7.09 minutos, pero este resultado depende de una disminución muy exigente del tiempo de atención.

Por su parte, M/M/3 logra estabilizar el sistema, pero con un tiempo de espera promedio de 28.10 minutos, lo cual no es adecuado para un servicio de heladería. M/M/4 presenta un W_q de 1.53 minutos, siendo el escenario más equilibrado entre estabilidad y calidad del servicio.

Gráfica 13. Longitud promedio de cola por escenario



La longitud promedio de cola confirma la superioridad del escenario M/M/4. Mientras M/M/1 y M/M/2 permanecen inestables, M/M/3 genera una cola promedio de 21.54 clientes, debido a que el sistema está muy cerca del límite de saturación. En cambio, M/M/4 reduce la cola promedio a 1.18 clientes.

Este resultado muestra que M/M/3 no es suficiente desde el punto de vista operativo, aunque sea estable matemáticamente. La alternativa más conveniente es M/M/4.

8. PROPUESTA DE MEJORA

Con base en los resultados obtenidos, se propone implementar un esquema de refuerzo operativo durante la franja de mayor demanda. El escenario M/M/4 representa la alternativa más conveniente, ya que reduce la utilización por servidor a $\rho = 0.72$, la longitud promedio de cola a 1.18 clientes y el tiempo promedio de espera a 1.53 minutos.

Esta recomendación no implica mantener cuatro servidores durante toda la jornada, sino activar capacidad adicional en el periodo crítico, aproximadamente entre las 12:30 p.m. y las 2:00 p.m. Además, los servidores pueden distribuirse por funciones, como toma de pedido, cobro, preparación y entrega, con el fin de aumentar la capacidad efectiva del sistema sin depender únicamente de cajas adicionales [3],[5],[9].

Los resultados comparativos muestran lo siguiente:

Tabla 6. Comparación cantidad de servidores

Escenario	ρ	Lq	Wq	Estado
M/M/1	2.88	No aplica	No aplica	Saturado
M/M/2	1.44	No aplica	No aplica	Saturado
M/M/3	0.96	21.54	28.10 min	Estable crítico
M/M/4	0.72	1.18	1.53 min	Estable recomendable

Aunque M/M/3 logra que ρ sea menor que 1, su utilización queda demasiado cerca del límite de estabilidad. Esto genera tiempos de espera elevados y una cola promedio considerable. Por tanto, M/M/3 no se considera suficiente para garantizar una buena experiencia del cliente.

M/M/4, en cambio, permite operar con mayor holgura, reduce la cola promedio y disminuye el tiempo promedio de espera a un nivel aceptable. Este comportamiento es coherente con los modelos M/M/c, en los cuales

el aumento del número de servidores reduce la carga promedio asignada a cada punto de atención [1].

Como complemento, se recomienda implementar acciones operativas que reduzcan el tiempo promedio de servicio y su variabilidad:

Tabla 7. Posibles acciones para reducir tiempo de servicio

Acción complementaria	Impacto esperado
Pre-alistamiento de productos de alta demanda	Reduce tiempos de servicio
Separación de funciones entre caja y entrega	Aumenta eficiencia operativa
Menú visible antes de llegar a caja	Reduce tiempo de decisión
Refuerzo temporal en hora pico	Aumenta capacidad sin afectar toda la jornada
Estandarización del proceso de atención	Disminuye variabilidad del servicio

Estas acciones pueden contribuir a mejorar el desempeño del sistema, pero los resultados muestran que la intervención más efectiva es aumentar la capacidad durante la hora pico.

9. DISCUSIÓN

Los resultados obtenidos confirman que la utilización es un indicador crítico para evaluar el desempeño de sistemas de atención [2],[3],[10]. Como señalan Saini, Singh y Sharma, cuando la utilización se aproxima al límite de estabilidad, los tiempos de espera y la longitud de cola pueden aumentar de manera significativa [2],[5],[10]. Este comportamiento se observa con claridad en la franja de la tarde, donde la alta tasa de llegada y el mayor tiempo promedio de servicio generan saturación bajo la configuración M/M/1.

La corrección del cálculo de λ fue fundamental para obtener un diagnóstico realista. Si se calculaba λ únicamente con los clientes atendidos completamente, el sistema parecía estar cerca de la estabilidad. Sin embargo, al considerar todos los clientes que llegaron, se evidencia que la franja de la tarde está realmente saturada.

Este hallazgo modifica la propuesta inicial del artículo. Antes se planteaba M/M/2 como solución principal, pero con los parámetros corregidos se observa que M/M/2 mantiene una utilización de $\rho = 1.44$, por lo que no logra estabilizar el sistema. M/M/3 alcanza estabilidad matemática, pero con una utilización de $\rho = 0.96$, lo cual genera tiempos de espera altos. Por esta razón, M/M/4 es la alternativa más adecuada.

La comparación de escenarios muestra que el aumento de servidores tiene un efecto directo sobre la reducción de la utilización por servidor. Este comportamiento es consistente con los modelos M/M/c, los cuales permiten representar sistemas donde la capacidad de servicio se distribuye entre varios servidores [1].

10. CONCLUSIONES

El estudio permitió evaluar el desempeño operativo de la Heladería Crepes & Waffles mediante teoría de colas y simulación en Python. Los resultados muestran una diferencia significativa entre la franja de la mañana y la franja de la tarde.

En la mañana, el sistema opera bajo condiciones estables, con una utilización de $\rho = 0.47$. Esto indica que un solo servidor es suficiente para atender la demanda observada durante esa franja. La cola promedio y el tiempo de espera se mantienen en niveles razonables.

En la tarde, el sistema presenta saturación bajo el modelo M/M/1, con una utilización de $\rho = 2.88$. Esto significa que la demanda supera ampliamente la capacidad de atención de un solo servidor. Debido a esta condición, las métricas estacionarias como L_q , W_q , L y W no son aplicables para el escenario base. Este resultado es consistente con la teoría de colas, donde la estabilidad depende de que la capacidad de servicio sea superior a la demanda promedio [2],[3],[5].

La simulación en Python permitió visualizar el crecimiento de la cola y comparar diferentes escenarios de mejora. Los resultados muestran que M/M/2 no es suficiente para estabilizar el sistema, ya que mantiene $\rho = 1.44$. M/M/3 logra estabilidad matemática, pero opera en una condición crítica con $\rho = 0.96$ y un tiempo promedio de espera elevado. Por tanto, M/M/4 representa la mejor alternativa entre los escenarios evaluados, al reducir la utilización a $\rho = 0.72$, la cola promedio a 1.18 clientes y el tiempo promedio de espera a 1.53 minutos.

Finalmente, se recomienda implementar refuerzo de personal durante la franja de mayor demanda, acompañado de mejoras operativas orientadas a reducir el tiempo de servicio y su variabilidad. El análisis M/M/c evidenció que aumentar el número de servidores durante la franja de mayor demanda permite reducir la utilización por servidor y mejorar el desempeño operativo del sistema [1].

11. LIMITACIONES

El estudio presenta algunas limitaciones que deben tenerse en cuenta. En primer lugar, la recolección de datos se realizó durante una sola hora por franja, lo que limita la representatividad estadística de los resultados. En segundo lugar, algunos clientes no alcanzaron a completar el ciclo de atención durante el periodo observado, por lo que el cálculo de μ se realizó únicamente con los servicios completos disponibles.

Para futuros estudios se recomienda ampliar el periodo de observación a varios días, incluir diferentes franjas horarias, validar estadísticamente las distribuciones de llegada y servicio, y considerar modelos con capacidad finita o abandono de clientes, como balking y reneging, los cuales pueden representar con mayor realismo el comportamiento de los clientes ante esperas prolongadas.

Además, no se realizaron pruebas formales de bondad de ajuste para validar si las llegadas

siguen una distribución Poisson y si los tiempos de servicio se ajustan a una distribución exponencial. Por ello, los resultados deben interpretarse como una aproximación útil para el diagnóstico operativo, pero no como una estimación definitiva del comportamiento del sistema [8].

Para futuros estudios se recomienda ampliar el periodo de observación a varios días, incluir diferentes franjas horarias, validar estadísticamente las distribuciones de llegada y servicio, y considerar modelos con capacidad finita o abandono de clientes.

12. REFERENCIAS

- [1] Chaudhary, H., Sharma, G., Nishad, D. K., & Khalid, S. (2025). *Advanced queueing and scheduling techniques in cloud computing using AI-based model order reduction*. Discover Computing, 28(75). <https://doi.org/10.1007/s10791-025-09581-7>
- [2] Saini, B., Singh, D., & Sharma, K. C. (2024). *Application of Queueing Theory to Analyze the Performance Metrics of Manufacturing Systems*. Asian Research Journal of Mathematics, 20(12), 84–95. <https://doi.org/10.9734/arjom/2024/v20i12876>
- [3] D. Gross, J. F. Shortle, J. M. Thompson, and C. M. Harris, *Fundamentals of Queueing Theory*, 5th ed. Hoboken, NJ, USA: Wiley, 2018. <https://download.e-bookshelf.de/download/0010/9228/27/L-G-0010922827-0027094516.pdf>
- [4] F. S. Hillier and G. J. Lieberman, *Introduction to Operations Research*, 11th ed. New York, NY, USA: McGraw-Hill, 2021. https://info.mheducation.com/rs/128-SJW-347/images/Preface_Hillier_Intro_Operations_Research_11e.pdf
- [5] L. Kleinrock, *Queueing Systems*, Volume 1: Theory. New York, NY, USA: Wiley, 1975. <https://ia601403.us.archive.org/13/items/in.ern.et.dli.2015.134547/2015.134547.Queueing-Systems-Volume-1-Theory.pdf>

- [6] J. Banks, J. S. Carson, B. L. Nelson, and D. M. Nicol, *Discrete-Event System Simulation*, 5th ed. Upper Saddle River, NJ, USA: Pearson, 2010.
https://api.pageplace.de/preview/DT0400.9781292037264_A24620807/preview-9781292037264_A24620807.pdf
- [7] A. M. Law, *Simulation Modeling and Analysis*, 5th ed. New York, NY, USA: McGraw-Hill, 2015.
<https://ndl.ethernet.edu.et/bitstream/123456789/87806/5/Simulation%20Modeling%20and%20Analysis%20by%20Averill%20M%20Law%20%28z-lib.org%29.pdf>
- [8] J. Medhi, *Stochastic Models in Queueing Theory*, 2nd ed. San Diego, CA, USA: Academic Press, 2002. https://library-search.open.ac.uk/discovery/fulldisplay/alma9952483922002316/44OPN_INST:VU1
- [9] H. A. Taha, *Operations Research: An Introduction*, 10th ed. Upper Saddle River, NJ, USA: Pearson, 2017.
<https://zalamsyah.staff.unja.ac.id/wp-content/uploads/sites/286/2019/11/9-Operations-Research-An-Introduction-10th-Ed.-Hamdy-A-Taha.pdf>
- [10] S. Asmussen, *Applied Probability and Queues*, 2nd ed. New York, NY, USA: Springer, 2003. <https://epdf.pub/applied-probability-and-queues5ffbb8398d9e1e8f7d7e1b6359321ac326324.html>